

开题报告

一、题目

中文题目：检测引导的动态扩散净化模型及其在对抗防御中的应用研究

英文题目：Research on Detection-Guided Dynamic Diffusion Purification Model for Adversarial Defense

二、摘要

对抗攻击已成为制约深度学习模型安全性的关键瓶颈。基于扩散模型的净化方法，凭借其强大的数据流形建模与高保真重建能力，正引领对抗防御领域的研究前沿。然而，现有方法普遍采用静态净化策略（如固定的噪声水平与去噪步数），这种“一刀切”的方式难以在鲁棒性、保真度与计算效率这三个核心指标间取得理想平衡：净化强度过弱则无法清除强对抗扰动，过强则会不必要地损害干净图像的细节并造成显著的计算开销。

为突破此困境，本研究提出一种检测引导的动态扩散净化框架（Detection-Guided Dynamic Purification, DDPurify）。该框架的核心思想是将对抗样本检测与自适应净化过程深度耦合，构建一个智能的闭环反馈系统。首先，我们设计了一个多模态对抗检测器，通过融合图像在结构域、频域以及流形空间的多维度特征，实现对输入样本对抗性的精准、鲁棒评估。其次，基于检测器输出的量化对抗分数，我们提出一种新颖的迭代反馈式净化策略。该策略将净化过程分解为一系列温和的迭代步骤，在每一步迭代前，都将重新评估当前图像的残余对抗性，并利用一个连续映射函数动态调整该步的净化强度。重要的是，若图像在任何一步被判定为足够“干净”，净化循环将提前中止，从而在保证防御效果的同时，最大化处理干净或弱对抗样本时的效率。

本研究将在 CIFAR-10 和 ImageNet 等标准数据集上，对所提出的 DDPurify 框架进行全面评估。预期实验结果将表明，与现有固定策略的净化方法相比，本框架能够在多种对抗攻击下，实现更优的鲁棒性-准确性权衡曲线，并显著降低在混合数据集上的平均净化时间。

三、关键词

对抗防御；扩散模型；动态净化；对抗样本检测；自适应方法；深度学习安全

四、立题依据

1. 研究意义 (工程价值)

近十几年来，以深度神经网络（DNNs）为核心的人工智能技术取得了飞跃式发展，并已深度渗透到社会生产和日常生活的方方面面，在图像识别、自动驾驶、医疗影像分析等关键领域扮演着越来越重要的角色。然而，Szegedy 等人开创性的研究揭示了 DNNs 固有的脆弱性：攻击者仅需向输入数据添加人眼难以察觉的微小扰动，便可轻易诱导模型做出完全错误的判断。这种被称为“对抗样本”的威胁，已成为制约人工智能技术在安全攸关系统中推广应用的关键瓶颈。本课题的研究意义和核心工程价值，在于直面当前最前沿的对抗净化技术在走向实际部署过程中所遇到的根本性困境，即鲁棒性、保真度与计算效率三者之间的尖锐矛盾。现有的扩散净化方法普遍采用静态策略，这种“一刀切”的方式导致了一个难以调和的性能权衡：为抵御强攻击而设定的高强度净化，虽能提升鲁棒性，却会不可避免地损害

干净图像的细节，造成“误伤”，降低模型在正常业务场景下的性能；反之，为保护保真度而采用的低强度净化，则在真正的攻击面前形同虚设。

本研究提出的动态框架，致力于通过对每个样本进行“个性化”防御，打破这一性能僵局，寻求在鲁棒性-准确性权衡曲线上达到新的帕累托最优。更重要的是，在自动驾驶、金融风控等实际应用中，系统处理的数据流绝大多数是良性的，对抗样本的出现是低概率事件。静态净化方法的高昂且恒定的计算开销，使得系统必须为小概率风险付出巨大的、持续的性能代价，这在追求低延迟和高吞吐的工程实践中是难以接受的。本课题通过引入检测引导的提前中止机制，为良性样本开辟“绿色通道”，有望将系统的平均处理延迟降低一个数量级以上，从而极大地提升了先进防御技术在资源受限或实时性要求高的场景下的部署可行性。最终，本研究致力于推动防御范式向智能化、实用化演进。我们认为，防御系统不应是一个固定的“过滤器”，而应是一个具备感知-决策-行动能力的智能闭环控制系统。这种范式上的革新，不仅能更精细化地解决当下的性能权衡问题，也为未来应对更加复杂、多变的攻击形态提供了更具弹性和扩展性的架构基础。

2. 国内外研究现状 (工程应用现状)

为应对日益严峻的对抗样本威胁，学术界和工业界已提出多种防御策略，但这些方法在有效性、通用性和实用性方面仍存在诸多挑战。对抗训练（Adversarial Training, AT）作为增强模型内在鲁棒性的主流方法，通过在训练阶段向模型“喂食”对抗样本，迫使模型学习更鲁棒的特征。尽管有效，其工程局限性十分明显：不仅训练成本高昂，且往往以牺牲模型在干净样本上的准确率为代价，还可能对特定攻击类型产生过拟合。更关键的是，AT 需要对模型进行重新训练，对于已经部署和验证完毕的深度学习系统，修改网络参数会引入不可预知的风险，这在实际应用中往往是不可行的。另一类检测性防御旨在区分真实样本和对抗样本，其优势在于速度快，但核心缺陷在于“只检测，不分类”。在许多应用场景中，仅仅告警是不够的。例如，在智能驾驶中，如果系统仅能识别出路边的停车标志是对抗样本，却无法得知其真实意图，那么紧急刹车或忽略标志都可能导致危险。系统需要的是一个可靠的分类结果。

鉴于上述方法的局限性，基于预处理的防御因其无需修改已部署分类器、具有良好兼容性的优点而备受关注。此类方法在将图像送入分类器前进行预处理，旨在破坏对抗扰动。早期的 JPEG 压缩、特征变换等方法，因其变换过程固定、可预测，容易被攻击者“绕过”。近年来，基于生成模型的净化，特别是基于扩散模型的净化，凭借其卓越的图像生成能力，通过加噪-去噪过程将对抗样本投影回自然图像流形，实现了当前最先进的防御效果。

Nie 等人首次提出 DiffPure，证明了扩散模型可以有效去除对抗扰动。后续工作如 DDRM、LS-DDRM 等进一步提升了净化效果。然而，现有基于扩散模型的净化方法几乎都采用固定的超参数（如起始噪声水平 t ），这导致了以下问题：

<1>性能权衡不佳：为防御强攻击而设定的高强度净化，会严重损害干净图像的质量，导致干净准确率下降。

<2>资源浪费：对干净或弱对抗样本施加不必要的强净化，造成了大量的计算资源浪费，限制了其实时应用。

<3>缺乏自适应性：无法根据攻击的“强度”和“类型”来调整防御策略，显得不够智能。

目前，已有少量工作开始探索自适应净化，但大多依赖于简单的启发式规则或需要额外训练复杂的控制器。将对抗检测与净化过程深度融合，构建一个高效、鲁棒的闭环反馈系统，是该领域一个亟待解决且充满机遇的研究空白。

3. 主要参考文献及出处

五、 研究方案

1.研究总目标:

设计并实现一个检测引导的动态扩散净化框架（DDPurify），使其在对抗防御任务中，相比现有固定策略方法，能够实现更优的性能权衡（鲁棒性、保真度）和更高的计算效率。

2.研究内容:

- <1>多模态对抗检测器设计: 研究如何有效融合多种特征（小波、频域、扩散重构误差等）来构建一个准确且鲁棒的对抗性评估模块，并能输出量化的对抗性分数。
- <2>动态净化策略研究: 设计将对抗性分数映射到净化强度的连续函数，并构建迭代反馈式的净化循环机制，包括提前退出条件的设计。
- <3>框架集成与优化: 将检测器与动态净化策略整合成一个端到端的 DDPurify 框架，并对其进行性能优化和超参数调优。
- <4>全面实验验证: 在标准数据集上，使用多种攻击方法，对 DDPurify 框架的有效性、鲁棒性和效率进行全面评估，并与 SOTA 方法进行对比。

3.拟解决的关键问题:

- 关键问题一：如何准确且鲁棒地评估输入样本的对抗性？ 解决方案是设计多模态融合检测器，避免单一特征的局限性，提升对未知攻击的泛化能力。
- 关键问题二：如何将评估结果转化为最优的净化策略？ 解决方案是设计迭代反馈机制和连续映射函数，实现从“一刀切”到“精准施策”的转变。
- 关键问题三：如何在提升防御效果的同时，保证甚至提升计算效率？ 解决方案是通过提前退出机制，避免对非对抗性样本进行不必要的计算，从而优化平均处理时间。

4.拟采取的研究方法、技术路线及可行性分析

研究方法与技术路线:

阶段一：理论学习与基础复现 (1-2 月)

深入研究扩散模型（DDPM, DDIM）和对抗防御（AT, PGD, AutoAttack, DiffPure）的核心论文。基于 PyTorch，复现 DiffPure 等基线方法，搭建基础实验平台。

阶段二：多模态检测器研发 (3-4 月)

实现小波变换、FFT、弱扩散重构等多种特征提取器。

设计并训练一个轻量级的融合网络（如 MLP），将多维特征融合成单一的对抗性分数。

阶段三：动态净化框架构建 (5-7 月)

实现对抗性分数到净化强度 t 的连续映射函数。

构建迭代净化循环，并嵌入检测模块和提前退出逻辑。

将检测器与净化器整合成完整的 DDPurify 框架。

阶段四：实验评估与论文撰写 (8-12 月)

在 CIFAR-10 和 ImageNet 子集上进行大规模实验。

使用 PGD、CW、AutoAttack 等多种攻击进行评估。

与 DiffPure、DDRM 等 SOTA 方法进行详细对比，绘制性能权衡曲线和效率对比图。
撰写并投递会议/期刊论文。

技术路线遵循一个“评估-决策-执行”的闭环反馈逻辑：

- 1.输入与评估：输入图像首先进入多模态检测器，输出对抗性分数 S 。若 S 低于安全阈值 τ ，直接执行步骤 2。若 S 高于安全阈值 τ ，直接执行步骤 4。
- 2.进入净化循环：图像和分数 S 进入迭代净化模块。
- 3.迭代反馈：在循环的每一步：
 - a.重新评估当前图像的对抗性 S_i 。
 - b.决策：若 S_i 高于安全阈值 τ ，则提前中止。
 - c.调整与执行：若未中止，则根据 S_i 动态计算本步的净化强度，并执行一小段净化过程。
- 4.输出：净化完成的图像送入下游分类器。

可行性分析：

- <1>理论可行性：本研究基于成熟的扩散模型理论和对抗防御思想，提出的动态调整策略是对现有方法的合理改进和延伸，理论上可行。
- <2>技术可行性：研究所需技术（PyTorch、扩散模型库、对抗攻击库）均为开源且社区活跃，本人具备相关的编程和深度学习模型实现能力。
- <3>资源可行性：实验室拥有足够的 GPU 计算资源（如 NVIDIA A30/V100），可以支持本研究中涉及的模型训练和大规模实验。

5. 创新之处

- <1>框架创新：首次提出将对抗检测与扩散净化深度耦合，构建了一个闭环反馈式的动态防御框架，而非传统的“先检测、后处理”的串联模式。
- <2>检测器创新：设计了多模态融合的对抗性评估机制，比依赖单一特征的检测方法更为鲁棒和精准。
- <3>策略创新：提出了迭代反馈式的净化策略，结合连续强度映射和提前退出机制，实现了对每个样本“量身定制”的净化，在鲁棒性、保真度和效率三个维度上实现了更好的平衡。